

# 5.25 MAD改进

## 目前的实验设置 (5.19)

- Agent 1: qwen3:8b
- Agent 2: deepseek-r1:14b
- Agent 3: phi4:14b

## 版本机制说明

| 版本                       | 主要机制                                                                                                                                                     | 文件                                  |
|--------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------|
| 旧 5-agent mechanism 0522 | 5 agents; summary 替代前轮辩论内容; all_stable 退出; 原始 verdicts_stable 退出; 无 margin; 无 final evidence review; 无 answer repair 诊断                                  | quality_mechanism_60522_041936.json |
| margin 版 0523            | 在 verdicts_stable 上加安全条件: majority answer unchanged + margin >= 2; disputed final answer 改成最近两轮累计投票; 但还没有有效 final review                                 | quality_mechanism_60523_200608.json |
| final review 版 0524      | max_round 前增加 final evidence review; 保留 5-agent; 保留 summary 压缩; 保留 all_stable 和 verdicts_stable; 但 repair helper 当时开启, A5 仍大量 None                       | quality_mechanism_60524_032347.json |
| 最新 mechanism 0525        | 关闭 LLM repair, 只保留本地正则解析; 保留 raw response 诊断; 保留 final evidence review; 保留 all_stable summary 前置退出; 保留安全化 verdicts_stable / decompress 逻辑; 最终答案用最近两轮累计投票 | quality_mechanism_60525_220949.json |
| 5-agent debate baseline  | 5 agents; 固定 3 轮链式辩论; 不使用 summary; 不使用 early exit; 不使用 final review; 每轮直接传递前驱原始回答                                                                        | quality_debate_50q_3_020045.json    |

修改prompt之后的效果 (要求agent轻易不改动答案、将答案放在开头减少推理的token消耗)

| 方法        | Acc | Total Token | Avg Token/Q |
|-----------|-----|-------------|-------------|
| Single    | 68% | 226,674     | 4533.5      |
| SC        | 76% | 654,038     | 13,081      |
| Debate    | 78% | 2,631,857   | 52,637      |
| Mechanism | 76% | 2,276,120   | 45,522      |

mechanism 退出分布:

- all\_stable: 42 题, 正确 35 题, 83.3%
- verdicts\_stable: 8 题, 正确 3 题, 37.5%

## 四分类结果

这里“辩论前”我按 mechanism 的 R0 多数投票算, “辩论后”按 mechanism 最终答案算。

| 类型    | 含义                    | 数量 | 占比  | 样本 ID                                                                                 |
|-------|-----------------------|----|-----|---------------------------------------------------------------------------------------|
| ✓ → ✓ | R0 本来对，mechanism 后仍然对 | 34 | 68% | 1,3,4,5,6,7,9,12,13,16,18,20,21,22,23,24,25,26,27,28,29,30,31,32,33,34,35,36,37,38,39 |
| ✓ → ✗ | R0 本来对，mechanism 后改错  | 2  | 4%  | 36,38                                                                                 |
| ✗ → ✓ | R0 本来错，mechanism 后纠正  | 4  | 8%  | 0,10,14,41                                                                            |
| ✗ → ✗ | R0 本来错，mechanism 后仍错  | 10 | 20% | 2,8,15,17,21,26,27,28,29,30,31,32,33,34,35,36,37,38,39                                |

## Token 消耗分析

最新 mechanism：

| 项             | Token     | 占总 token |
|---------------|-----------|----------|
| Agent 辩论调用    | 2,120,282 | 93.15%   |
| Summarizer 调用 | 155,838   | 6.85%    |
| 总计            | 2,276,120 | 100%     |

最新 50 题中：

| 压缩模式    | 次数 | 是否调用 LLM |
|---------|----|----------|
| FULL    | 85 | 是        |
| PARTIAL | 17 | 是        |
| NONE    | 9  | 否        |

当前有 42 次 final-round FULL summary 是在马上 all\_stable 退出前生成的。

也就是说代码现在的顺序是：

生成 FULL summary  
然后发现 all\_stable  
然后退出

这部分 summary 根本不会被下一轮 agent 使用。如果把 all\_stable 检查提前到 summarizer 之前，可以做到：

准确率完全不变  
final answer 完全不变  
直接少掉约 42 次 FULL summarizer 调用  
估计可省：42 × 1,394 ≈ 58,500 tokens



最后修改流程改成：

本轮 agent 回答结束  
compute\_verdicts  
如果 round >= 2 且 all\_stable 满足：  
    直接退出，不生成 summary  
否则：  
    再 generate\_summary  
    再检查 verdicts\_stable / deadlock

对比结果是：

| 指标                     | 旧版  | 最新版 |
|------------------------|-----|-----|
| 表面 FULL 轮次             | 85  | 96  |
| all_stable 且最后一轮是 FULL | 42  | 48  |
| 实际 FULL summary 调用     | 85  | 48  |
| 实际 summary 总调用         | 102 | 51  |

对应 token 变化：

| 指标               | 旧版        | 最新版       | 变化        |
|------------------|-----------|-----------|-----------|
| Summarizer token | 155,838   | 66,283    | -89,555   |
| 总 token          | 2,276,120 | 2,117,976 | -158,144  |
| 平均每题 token       | 45,522.40 | 42,359.50 | -3,162.90 |

no\_verdict\_stable 的结果

Token 对比

| 方法                 | 准确率 | 总 token   | Agent token | Summarizer token | 平均轮数 |
|--------------------|-----|-----------|-------------|------------------|------|
| mechanism          | 76% | 2,276,120 | 2,120,282   | 155,838          |      |
| no_verdicts_stable | 82% | 2,203,462 | 2,056,596   | 146,866          |      |

压缩模式分布：

| 方法                 | FULL | PARTIAL | NONE | LLM summary 调用 |
|--------------------|------|---------|------|----------------|
| mechanism          | 85   | 17      | 9    | 102            |
| no_verdicts_stable | 99   | 3       | 4    | 102            |

为什么去掉 verdicts\_stable 后 token 反而更少？

PARTIAL 比 FULL 更贵；不稳定分歧轮越多，token 越高；这次 no\_verdicts\_stable 更少进入 PARTIAL，所以更省。

3-agent no\_verdicts\_stable：

```
early_exit_rate = 100%
early_exit_accuracy = 82%
all_stable: 49 题
```

增加到5/7个agent效果如何

新增 5-agent：

```
A1 deepseek-r1:14b
A2 gemma4:e4b-it-q4_K_M
A3 phi4:14b
A4 glm4:9b
A5 qwen3.5:9b
```

新增 7-agent：

- A1 deepseek-r1:14b
- A2 gemma4:e4b-it-q4\_K\_M
- A3 phi4:14b
- A4 glm4:9b
- A5 qwen3.5:9b
- A6 mistral:7b
- A7 command-r7b:7b

整体对比

| 设置                | 准确率 | 总 token   | 每题 token | 平均轮数 | 早退率 |
|-------------------|-----|-----------|----------|------|-----|
| 5-agent mechanism | 78% | 5,757,702 | 115,154  | 3.94 |     |
| 7-agent mechanism | 76% | 7,877,852 | 157,557  | 3.96 |     |

| 方法                | Agent 数 | 准确率 | 总 token   | 每题 token   |
|-------------------|---------|-----|-----------|------------|
| 5-agent debate    | 5       | 80% | 4,396,379 | 87,927.60  |
| 5-agent mechanism | 5       | 78% | 5,757,702 | 115,154.00 |
| 7-agent mechanism | 7       | 76% | 7,877,852 | 157,557.00 |

5-agent mechanism token消耗情况

| 来源         | Prompt    | Completion | Total     | 占比     |
|------------|-----------|------------|-----------|--------|
| Agent 辩论调用 | 4,974,371 | 453,558    | 5,427,929 | 94.27% |
| Summarizer | 232,986   | 96,787     | 329,773   | 5.73%  |
| 总计         | 5,207,357 | 550,345    | 5,757,702 | 100%   |

最大头不是 summarizer，而是 agent 每轮都要读 QuALITY 长 passage。Summarizer 只占 5.73%。

退出原因

| 退出原因            | 5-agent | 5-agent 准确率 | 7-agent | 7-agent 准确率 |
|-----------------|---------|-------------|---------|-------------|
| all_stable      | 2       | 100%        | 4       | 75%         |
| verdicts_stable | 35      | 80%         | 33      | 78.80%      |
| max_rounds      | 13      | 69.20%      | 13      | 69.20%      |

压缩和 token

| 设置      | FULL | PARTIAL | NONE | Summary 调用 | Summarizer token |
|---------|------|---------|------|------------|------------------|
| 5-agent | 21   | 131     | 45   | 152        | 329,773          |
| 7-agent | 19   | 131     | 48   | 150        | 367,231          |

四分类结果

| 类型    | 5-agent | 7-agent |
|-------|---------|---------|
| ✓ → ✓ | 37      | 33      |
| ✓ → ✗ | 3       | 2       |
| ✗ → ✓ | 2       | 5       |
| ✗ → ✗ | 8       | 10      |

而是 agent 每轮都要读 QuALITY 长 pass…



用户075165 40 分钟前

所以当前机制在 MMLU-Pro 上看不到压缩收益，是因为题干短；在 QuALITY 上理论上应该更有压缩收益，但现在收益仍不明显，是因为压缩对象选错了：压缩了辩论历史，却没有压缩最大的输入源 passage。

👉 主要目标

- 减少 max\_rounds
- 让 verdicts\_stable 更早且更可靠地退出
- 对长期 disputed 样本做 final evidence review

总结表

| Agent | 模型                   | 参数量      | 公司         | Instruct?       | 显存     |
|-------|----------------------|----------|------------|-----------------|--------|
| A1    | deepseek-r1:14b      | 14B(蒸馏)  | DeepSeek   | 推理模型，自带         | ~10GB  |
| A2    | gemma4:e4b-it-q4_K_M | 4.5B(有效) | Google     | ✅ -it           | ~5GB   |
| A3    | phi4:14b             | 14B      | Microsoft  | ✅ 默认            | ~10GB  |
| A4    | glm4:9b              | 9B       | 智谱         | ✅ chat版         | ~6GB   |
| A5    | qwen3.5:9b           | 9B       | 阿里         | ⚠️ 默认带 thinking | ~7GB   |
| A6    | mistral:7b           | 7B       | Mistral AI | ✅ v0.3          | ~4.5GB |
| A7    | command-r7b:7b       | 7B       | Cohere     | ✅ 对话模型          | ~4.5GB |

最推荐的组合

📌 如果目标是让 5-agent mechanism 超过 5-agent debate baseline，我建议先做这个组合：

- A. 保留 all\_stable summary 前置退出
- B. verdicts\_stable 加安全条件：  
majority answer unchanged + margin >= 2
- C. 对不安全的 verdicts\_stable 触发 decompress 一轮
- D. max\_round 前加 final evidence review
- E. disputed final answer 改成最近两轮累计投票

这套逻辑是：

- 稳定且强多数 -> 早退
- 稳定但弱多数 -> 解压再辩
- 长期不收敛 -> evidence review 裁决
- 最终仍分歧 -> 历史投票而不是最后一轮偶然投票

总体对比

| 方法                       | Acc | Total tokens | Avg tokens/q | Avg rounds | Ear |
|--------------------------|-----|--------------|--------------|------------|-----|
| 5-agent debate           | 80% | 4,396,379    | 87,928       | 固定 3 轮     | -   |
| 旧 5-agent mechanism 0522 | 78% | 5,757,702    | 115,154      | 3.94       |     |
| previous mechanism 0524  | 78% | 5,890,560    | 117,811      | 4          |     |
| 最新 mechanism 0525        | 80% | 6,102,324    | 122,046      | 4.16       |     |

最新 mechanism 的准确率提升到了 80%，和 5-agent debate 持平；但 token 成本比 debate 高很多，多了约 1.71M tokens，约 +38.8%。所以这版的主要改进是 准确率恢复，不是 token 节省。

相对之前 mechanism 的改进

| 指标                  | 524    | 最新 0525 | 变化    |
|---------------------|--------|---------|-------|
| Acc                 | 78%    | 80%     | 0.02  |
| Early rate          | 72%    | 62%     | -10%  |
| Early exit acc      | 77.80% | 87.10%  | 0.093 |
| verdicts_stable 数   | 33     | 25      | 更少    |
| verdicts_stable acc | 78.80% | 88.00%  | 更可靠   |
| max_rounds 数        | 14     | 19      | 更多    |
| max_rounds acc      | 78.60% | 68.40%  | 更差    |

这里最重要的发现是：最新机制变得更“谨慎”了，早退少了，但早退质量提高了。verdicts\_stable 从 33 个减少到 25 个，准确率从 78.8% 提到 88%。这说明安全条件和流程调整确实减少了一部分不安全早退。

但代价是更多样本进入 max\_rounds，而 max\_rounds 的准确率只有 68.4%，导致整体只提升 2%。

token 消耗在哪里

最新 mechanism token 拆分：

| 部分                 | tokens    | 占比     |
|--------------------|-----------|--------|
| agent debate calls | 5,663,337 | 92.80% |
| summarizer         | 352,319   | 5.77%  |
| final review       | 86,668    | 1.42%  |
| total              | 6,102,324 | 100%   |

所以最大头仍然不是 summarizer，而是 agent 每轮反复读 QuALITY 长 passage。

final evidence review 的效果

最新有 19 个 max\_rounds，final review 调用了 19 次，消耗 86,668 tokens。

但它几乎没有带来净收益：

| 项           | 数量 |
|-------------|----|
| max_rounds  | 19 |
| fallback 正确 | 13 |
| review 正确   | 13 |
| review 改答案  | 2  |
| 改对          | 0  |
| 改错          | 0  |

也就是说，final review 有时改答案，但没有把错题改对。它目前主要增加 token，没有显著提升准确率。

当前仍然存在的问题

1. A5 仍然大量 None
- 最新 50 题里 A5 有 194 次 None：
- R0: 40

R1: 37

R2: 35

R3: 28

R4: 23

A5 仍然大量 None

用户075165 24 分钟前 （编辑过）

后续会将 qwen3.5:9b 改成更稳定的 qwen3:8b，再看准确率

- R5: 18
  - R6: 13
2. 这说明 5-agent 实际经常退化成 4-agent，verdict 判断会被污染。
3. summarizer 没压缩 QuALITY passage  
当前压缩的是 debate history，不是长 passage。agent 每轮仍然读完整 passage，所以 token 大头没被优化。
4. max\_rounds 是主要准确率瓶颈  
最新 max\_rounds 19 题，只有 13 题正确，准确率 68.4%。早退变安全后，更多难题被推到 max\_round，但 max\_round 没有被有效解决。
5. final review 没有产生有效纠错  
它消耗了 86k tokens，但没有把错题改对。
6. token 成本比 debate（baseline）高  
最新 mechanism 准确率和 debate 一样，但 token 多 38.8%，目前不能说比 debate 更优。

| summarizer 没压缩 QuALITY passage



用户075165 30 分钟前

是否需要增加对 passage 的压缩？

| max\_rounds



用户075165 29 分钟前（编辑过）

max\_round 改进的方法：是偏向于减少进入到 max\_round 当中还是修改 max\_round 的机制

| final review



用户075165 28 分钟前（编辑过）

后续实验可能会注释掉这个功能，重新设计进入到 max\_round 的题目