

6.3 MAD改进

Adaptive resolver（没有加入针对性的早退机制）

all_stable:

直接退出

disputed:

不看 verdicts_stable/deadlock

计算 entropy + margin + TV distance

(对应阈值 $margin \geq 2/normalized_entropy \leq 0.55/TV \leq 0.20$)

如果分布不稳定:

继续辩论

如果分布稳定但仍 disputed:

触发 Dispute Resolver

Resolver 做 Evidence grounding / Reason quality / Option contrast / Error diagnosis

注入下一轮上下文

max_round:

Final Review

1. Evidence grounding 每个答案是否有明确证据支持。

answer -> evidence span / cited sentence / supporting fact

如果一个选项只有“感觉合理”，但另一个选项有直接证据，应该偏向后者。

2. Reason quality 判断理由是不是有效推理，而不是重复结论。

低质量理由包括：

- 复述选项
- 只说 “therefore A”
- 引用了无关信息
- 忽略题目限定词
- 偷换概念

3. Option contrast disputed 选项不能单独看，要成对比较。

- Why A over B?
- What evidence rules out B?
- What would need to be true for B to be correct?

很多错误不是因为正确选项没人支持，而是因为错误选项没有被有效排除。

4. Error diagnosis

判断分歧来源：

- evidence disagreement
- question interpretation disagreement
- option ambiguity
- arithmetic/logical mistake
- hallucinated fact

不同错误类型应该走不同处理方式。

整体结果

方法	Acc	Avg rounds	Total tokens	Exit 分布
quality debate	76%	固定 3	4.32M	-
no_verdict_stable_no_deadlock	74%	3.58	5.29M	all_stable 36, max_rounds 14
adaptive resolver	76%	3.52	5.35M	all_stable 36, max_rounds 14
no_verdicts_stable	80%	3.2	4.81M	all_stable 34, deadlock 6, max_rounds 10
安全版 mechanism	80%	3.24	4.87M	all_stable 31, verdicts_stable 8, deadlock 1, max_rounds 10

Adaptive resolver 的 exit 准确率：

exit	题数	正确率
all_stable	36	77.80%
max_rounds	14	71.40%

Adaptive resolver加入针对性早退机制+放宽调用机制+confidence

 all_stable:
直接退出

resolver trigger:
if round >= 2 and n_disputed > 0 and resolver_used == False:
run resolver
inject into next round

resolver-confirmed exit:
if resolver_used and next round majority == resolver_answer
and confidence >= medium
and margin >= 2
and entropy <= 0.55:
exit

otherwise:
continue to max_round

max_round:
final review

改动地方：

1. 增加早退机制：只有满足 confidence in {medium, high} 才会退出。
2. 放宽resolver的调用：只要 R2 后仍 disputed 就触发一次，每道题最多触发一次 resolver ，后续仍是 disputed 则进入 max_round。

整体对比

方法	Acc	Total tokens	Avg/q	Avg rounds	说明
Single	70%	224,893	4,498	-	A1 单模型
SC	76%	1,072,357	21,447	-	5-agent 独票
Debate baseline	76%	4,315,236	86,305	固定 3	baseline debate
no_verdicts_stable	80%	4,811,501	96,230	3.2	保留 deadlock
no_verdict_stable_no_deadlock	74%	5,289,281	105,786	3.58	只剩 all_stable_max_round
旧 adaptive resolver	76%	5,348,522	106,970	3.52	触发较窄，confirmed
新 adaptive resolver	80%	4,590,766	91,815	2.98	放宽触发 + resolver_confirmed
安全版 mechanism	80%	4,870,200	97,404	3.24	含安全化 verdicts_stable

和其他机制的早退准确率对比

版本	all_stable	verdicts_stable	deadlock	resolver_confirmed	max_round
安全版 mechanism	27/31 = 87.1%	5/8 = 62.5%	0/1 = 0%	-	8/10 = 80%
no_verdicts_stable	30/34 = 88.2%	-	3/6 = 50%	-	7/10 = 70%
no_deadlock	31/36 = 86.1%	-	-	-	6/14 = 42.9%
旧 adaptive	28/36 = 77.8%	-	-	-	10/14 = 71.4%
新 adaptive	31/36 = 86.1%	-	-	3/4 = 75%	6/9 = 66.7%

可以看到，新版主要改善了两点：

1. all_stable 恢复到高正确率：86.1%
2. max_round 数量从 14 降到 9

confidence in {medium, high}

用户075165 1 小时前
判断是由 llm 生成

优化方向：

high confidence 的 resolver 调用质量明显更好。

单次调用层面：

high： 28 次，最终题目正确率 89.3%

low： 3 次，最终题目正确率 33.3%

后续改进地方：（已完成✅✅✅）

- 1. Confidence 不能由 llm 直接生成。
- 2. 面对 low confidence 不注入完整 resolver analysis。

confidence 整体工作流程：

- 1. Resolver 生成结构化分析
↓
- 2. 代码把四个板块转成 score
↓
- 3. 得到 calibrated confidence
↓
- 4. 决定是否允许 resolver_confirmed early exit / 是否注入完整分析 / 是否进入 final review

2：四个板块的 score 还是由 llm 进行评估

3：这些 score 可以组成 resolver_quality_score：

```
resolver_quality_score =  
    0.35 * evidence_score  
+ 0.30 * reason_score  
+ 0.20 * contrast_score  
+ 0.15 * diagnosis_score
```

然后再和投票分布信号结合：

```
calibrated_confidence_score =  
    0.40 * vote_confirmation_score  
+ 0.60 * resolver_quality_score
```

其中 vote_confirmation_score 可以来自：

```
majority_match  
margin  
entropy
```

例如：

```
vote_confirmation_score =  
    0.4 * majority_match  
+ 0.3 * min(margin / 3, 1)  
+ 0.3 * (1 - normalized_entropy)
```

最后分档：

```
score >= 0.75 -> high  
score >= 0.55 -> medium  
else -> low
```

这样 confidence 就不是 LLM 自评，而是：

4: 分为high confidence/medium confidence/low confidence

High confidence:

```
如果 resolver_answer == next_round_majority
且 margin >= 2
则 resolver_confirmed early exit
```

操作: 直接退出 final_answer = resolver_answer

Medium confidence:

不建议直接退出, 可以:

```
继续一轮
但注入完整 resolver analysis
并要求 agent 专门检查 resolver 指出的 error
```

如果下一轮仍确认:

```
再退出
```

Low confidence:

不要注入完整分析, 避免误导。

操作:

```
只注入弱提示:
"Resolver could not confidently resolve the dispute.
Re-check the disputed options independently."
```

提高 ACC 的后续改进方向

1. all_stable 的改进

👉 all_stable 触发

↓

做 safety check:

- 1. R0 majority 是否一致
- 2. 历史加权投票是否支持当前答案
 - R0: 1.0
 - R1: 1.0
 - R2: 1.2
 - R3 及以后: 1.5
- 3. 是否发生过大规模答案迁移

例如 5-agent 下, 如果 3 个或更多 agent 在 R0 不是 A, 但 all_stable 时都变成 A, 就认为发生了大规模迁移, 判为不安全, 进入 challenge。

↓

如果安全:

直接退出

如果不安全:

进入 all_stable challenge，而不是普通 final review

all_stable challenge 可以分为两种

轻量版：

让 resolver 只检查 “当前一致答案是否可能是 groupthink”

输出：accept / challenge + alternative answer

强版：

independent verifier 独立读题，不看 agent 结论

如果 verifier 不同意当前 all_stable 答案，再进入 final review

2. final review 的改进（不采用加权？）

如果 entropy 高 / vote migration 大 / resolver low confidence：

标记 hard case 不早退用 stronger final judge

3. 答案质量来源？ 如果采用 question-aware evidence snippets 可以改善答案质量来源

V1 adaptive resolver

V2 + all_stable safety gate

V3 + stronger final review

V4 + question-aware evidence snippets

V2 + all_stable safety gate

整体对比

方法	准确率	总 token	平均轮数	主要问题
Single	70%	0.225M	-	单模型能力上限
SC	76%	1.07M	-	便宜但无辩论修正
Debate baseline	76%	4.32M	3	成本高，收益有限
V1 bugfix adaptive	74%	4.06M	2.6	resolver_confirmed 太冒进
V2 all_stable gate	80%	4.67M	3.02	resolver_confirmed 仍有错
no_verdicts_stable	80%	4.81M	3.2	deadlock 不稳定

早退分布：

退出类型	数量	正确数	准确率
all_stable_safety_accept	26	24	92.30%
resolver_confirmed	16	12	75.00%
all_stable_challenge_accept	1	0	0.00%
max_rounds	7	4	57.10%



resolver confirmed 条件满足后：

计算 influence_risk

如果 low risk:

resolver_confirmed_exit

如果 medium/high risk:

不退出

下一轮去掉完整 resolver analysis

只注入弱提示：

"Re-check independently; do not follow the resolver blindly."

risk 可以这样定义：

risk_score = 0

if pre_resolver_margin < 2: (*resolver 触发前，推荐答案在群体中不是强多数*)

risk_score += 1

if support_jump >= 2: (*resolver 注入后支持数突然大幅上升*)

risk_score += 1

if resolver_answer != R0_majority:

risk_score += 1

if resolver_answer was not top answer before resolver: (*resolver 推荐了一个在触发前不是多数的答案。*)

risk_score += 1

退出规则：

risk_score <= 1:

allow resolver_confirmed exit

risk_score >= 2:

block exit, continue one independent round

3-agent 推荐参数

weak_pre_resolver_margin: trigger_margin < 1

large_support_jump: support_jump >= 2

risk_score allow: risk_score <= 1

7-agent 推荐参数

weak_pre_resolver_margin: trigger_margin < 2 或 < 3

large_support_jump: support_jump >= 3

large migration: >= 5 agents # 当前 all_stable 用
ceil(7*0.6)=5

risk_score allow: risk_score <= 1

论文通用的表达是：

margin_ratio = margin / N
support_jump_ratio = support_jump / N

推荐规则：

weak_pre_resolver_margin: margin_ratio < 0.30

large_support_jump: support_jump_ratio >= 0.40

all_stable safety gate 的参数也要随 N 变（已完成✓✓✓）

现在大规模迁移: threshold = max(2, ceil(N * 0.60))