

6.12 MAD

V3的工作流程图

代码块

```
1  输入问题 + 选项 + 长文本
2      |
3      v
4  R0: 多个 Agent 独立回答
5      |
6      v
7  提取每个 Agent 的答案
8      |
9      v
10 构建 option-level verdict ledger
11     |
12     |-- 对每个选项判断:
13         include = 所有 agent 都选择该选项
14         exclude = 所有 agent 都不选择该选项
15         disputed = agent 对该选项有分歧
16     |
17     v
18 进入多轮 Debate
19     |
20     v
21 每轮 Agent 根据上下文更新答案
22     |
23     |-- 上下文包括:
24         上一轮 summary / capsule
25         前序 agent response
26         自己上一轮回答
27         resolver 分析, 如果有
28     |
29     v
30 再次提取答案并更新 option-level ledger
31     |
32     v
33 判断 compression mode
34     |
35     |-- NONE:
36         第一轮后仍有 disputed options
37         不调用 LLM summary
```

```

38         |         只生成规则化 debate capsule
39         |
40         | -- PARTIAL:
41         |         存在 disputed options
42         |         且已有上一轮 summary
43         |         LLM 总结 stable options
44         |         LLM 总结 disputed options 的 support / oppose reasons
45         |
46         | -- FULL:
47         |         没有 disputed options
48         |         原版 V3 使用 LLM 总结所有 include / exclude 理由
49         |
50         v
51 检查是否可以 early exit
52         |
53         | -- all_stable?
54         |         所有选项均为 include / exclude
55         |         当前答案连续稳定
56         |         |
57         |         v
58         |         all-stable safety gate
59         |         |
60         |         | -- 检查 current answer 是否等于 R0 majority
61         |         | -- 检查 current answer 是否被 history-weighted vote 支持
62         |         | -- 检查是否存在 large answer migration
63         |         |
64         |         | -- safe=True
65         |         |         -> all_stable_safety_accept
66         |         |         -> 输出最终答案
67         |         |
68         |         | -- safe=False
69         |         |         -> all_stable challenge
70         |         |         -> 若 challenge 接受共识:
71         |         |                 all_stable_challenge_accept
72         |         |                 输出最终答案
73         |         |         -> 否则继续 debate
74         |
75         | -- disputed but stable?
76         |         答案分布稳定
77         |         仍存在 disputed options
78         |         |
79         |         v
80         |         调用 dispute resolver
81         |         |
82         |         | -- 分析争议选项
83         |         | -- 给出 recommended answer
84         |         | -- 给出 evidence / reason quality / error diagnosis

```

```

85      |      |
86      |      v
87      |  resolver 分析注入下一轮 debate
88      |      |
89      |      v
90      |  下一轮 agent 是否确认 resolver answer?
91      |      |
92      |      | -- confirmed=False
93      |      |      -> 继续 debate
94      |      |
95      |      | -- confirmed=True
96      |      |      -> resolver influence gate
97      |      |
98      |      | -- 检查 resolver answer 注入前是否已是 top
answer
99      |      | -- 检查注入后 support jump 是否过大
100     |      | -- 检查 resolver answer 是否偏离 R0 majority
101     |      | -- 检查 pre-resolver margin 是否过弱
102     |      |
103     |      | -- safe=True
104     |      |      -> resolver_confirmed_influence_accept
105     |      |      -> 输出最终答案
106     |      |
107     |      | -- safe=False
108     |      |      -> 阻止 resolver-induced early exit
109     |      |      -> 继续 debate
110     |      |
111     |      | -- 未满足 early exit
112     |      |      -> 进入下一轮
113     |      |
114     |      v
115     |  达到 max rounds?
116     |      |
117     |      | -- No -> 下一轮 debate
118     |      |
119     |      | -- Yes
120     |      |      -> final evidence review
121     |      |      -> 输出最终答案

```

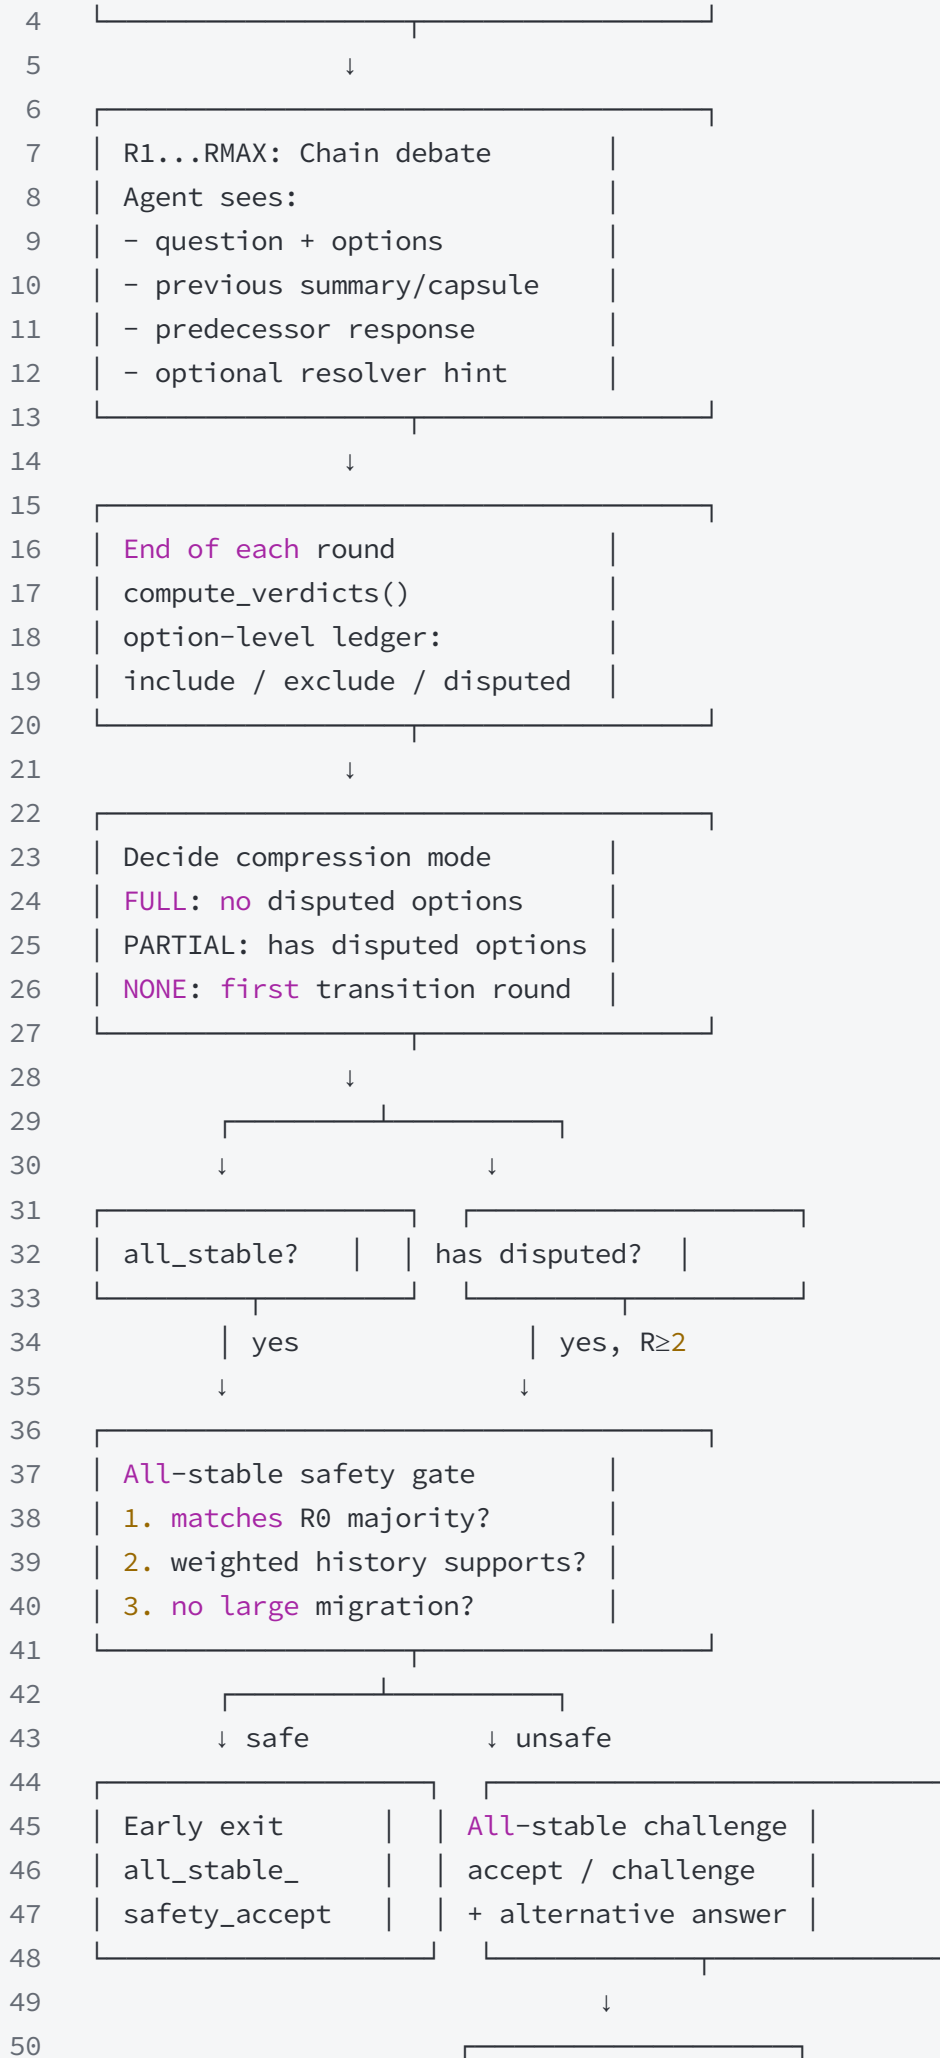
V4的工作流程

代码块

```

1  | _____|
2  | | R0: All agents answer alone |
3  | | No early exit               |

```



```
51 | Early exit |
52 | challenge result |
53 |_____|
```

```
54
55     disputed branch:
56     ↓
```

```
57 |_____|
58 | Dispute Resolver |
59 | Evidence grounding |
60 | Reason quality |
61 | Option contrast |
62 | Error diagnosis |
63 |_____|
```

```
64     ↓
65 |_____|
66 | Inject resolver analysis |
67 | into next debate round |
68 |_____|
```

```
69     ↓
70 |_____|
71 | Next round confirms resolver? |
72 |_____|
```

```
73 |
74 |   ↓ yes       ↓ no
75 |_____|
```

```
76 | Resolver Influence Gate |
77 | 1. weak pre-margin? |
78 | 2. large support jump? |
79 | 3. conflicts with R0 majority? |
80 | 4. not pre-resolver top? |
81 |_____|
```

```
82 |
83 |   ↓ low risk   ↓ high risk
84 |_____|
```

```
85 | Early exit | | Continue debate |
86 | resolver_confirmed_ | | with weak warning |
87 | influence_accept | | no blind following |
88 |_____| |_____|
```

```
89     ↓
90 |_____|
91 | Next round |
92 |_____|
```

```
93
94 If no safe early exit by MAX_ROUNDS:
95     ↓
```

```
96 |_____|
97 | Strong Final Evidence Review |
```

98		strongest configured agent	
99		decides final answer	
100			

V3 相比之前机制的核心改进

把 early exit 变成三层安全控制：

- 1. `all_stable safety gate` -----> 解决 “全体一致但可能 groupthink”
- 2. `resolver influence gate` -----> 解决 “resolver 诱导 agent 形成错误一致”
- 3. `strong final evidence review` -----> 解决 “跑满轮数后普通 majority/fallback 不可靠”

V3 + stronger final review + ResolverInfluenceGate

各模块表现：

V3 的提升来自 two-stage safety control:

- 1. 稳定共识由 all-stable safety gate 控制；
- 2. resolver 诱导的一致由 influence gate 控制；
- 3. 剩余高风险样本交给 strong final evidence review。

哪些 summary 可以不用 LLM?

我建议这样分：

V4 + question-aware evidence snippets

在V3基础上新增模块：

代码块

```
1  R0/R1:
2      agent 仍看完整 passage
3
4  R2+:
5      如果存在 disputed options:
6          从 passage 中按 question + disputed option 检索 evidence snippets
7          注入下一轮上下文
8          不替代完整 passage
9
10
11  当前 snippets 方法是: deterministic lexical retrieval (不用 LLM、embedding, 先用规则检索)
12  检索规则:
13  1. 从 QuALITY 的 Passage 中切 sentence/chunk
14  2. query = question + disputed option text
15  3. 用词重叠 + 简易 IDF 排序
16  4. 每个 disputed option 取 top-2 snippets
```

V4.1 lexical snippets:

完整 passage + question + options + question-aware evidence snippets + summary / resolver context （作用是显式提示关键证据，能不能提高准确率）

总体对比：

模块层面：

造成的原因：

- 1. snippets 可能强化了错误选项
- 2. resolver/challenge 更容易接受错误方向
- 3. final review 也可能被局部证据带偏

这会让 snippets 影响太早、太广。

有些 disputed 其实靠正常辩论可以解决，但 snippets 提前插入后，可能：

- 1. 强化错误选项
- 2. 让所有 agent 关注同一段局部证据
- 3. 破坏 agent 之间的独立性
- 4. 增加 groupthink

所以后续更合理的是，只在以下情况注入 snippets：

- 1. resolver_influence_blocked
- 2. max_round 前一轮
- 3. disputed 连续 2 轮存在
- 4. all_stable safety unsafe

后续要重点关注什么：

对于 V4，重点不是 token，第一版重点看准确率信号：

snippets 是否让 disputed 题更容易答对？ resolver_confirmed_influence_accept 是否更准？ max_round 是否减少？

重点分析这些指标：

- 1. snippets 触发次数 55次
- 2. snippets 触发题准确率 15/23 = 65.2%
- 3. disputed -> all_stable 的转化是否更准
- 4. resolver influence blocked 后是否被救回
- 5. max_round 数量是否下降 否，增高且正确率下降

如果 V4 50 题准确率没有提升，下一步优先改： retrieval quality

具体方向：

- 1. 从 lexical retrieval 升级到 embedding retrieval
- 2. snippets 不要只按 option 检索，还要加 question type
- 3. 对 retrieved snippets 做去重和 rerank
- 4. 对低质量 snippets 不注入，避免误导 agent

V4.2 embedding top-k snippets

完整原文 + embedding snippets + summary/context

总体对比：

V4.3 = V3 + selective embedding snippets

代码块

```
1 强触发：
2 1. all_stable safety failed
3 2. resolver_influence_blocked
4
5 弱触发：
6 3. disputed stalled for 2 rounds
7 4. max_round 前仍 disputed
8
9
```

- 10

强触发 → 一定注入 snippets
- 11

弱触发 → 只有同时满足低 confidence / 小 margin / 高 entropy 才注入

整体对比

V4.3 比 V4.2 多对 1 题，但比 V3 少对 3 题，而且 token 最高。

- V4.1 lexical snippets
- V4.2 embedding top-k snippets
- V4.3 embedding top-k + LLM rerank
- V5 snippets replace full passage
- 推荐实现顺序

summarize 替换

整体对比

- 1. reason inheritance 仍低于 V3 原版
原版 84%，最新 78%，差 3 题。说明 FULL LLM summary 里当前轮综合 reasoning 仍有价值，简单继承上一轮 reason 不能完全替代。
- 2. token 节省有限但存在
summary tokens 从 148,532 降到 130,742，约降 12%。相比纯 rule-only 的大幅降 token，inheritance 更稳但省得少。
- 3. FULL 模板变动会影响 resolver/PARTIAL，因为它改变了后续 agent 和 resolver 接收到的上下文质量。

替换原文passage

阶段 1：Evidence emphasis

full passage

目标：

不注入 snippets

只要求 agent 在已有完整 passage 中做 evidence check

阶段 2：Selective replacement

只在低风险题替代原文：

如果 all_stable safe： 已经退出，不需要 passage

如果 resolver_influence_blocked： 保留 full passage，不替代

如果 disputed 连续稳定但 evidence snippets 高质量： 用 snippets + summary 替代 full passage

阶段 3：Full replacement

R2+ 不再传 full passage

只传:question/options/stable option summary/disputed evidence/
snippets/debate/resolver summary

下一步数据集建议：优先选“长文本、多选项、答案有局部证据、baseline 容易被全文噪声干扰”的任务，embedding snippet 才更可能比 baseline 好。推荐顺序：

1. HotpotQA / 2WikiMultiHopQA：多跳证据检索明显，embedding snippets 有发挥空间。
2. MuSiQue：更难的多跳组合，适合证明 evidence routing 的价值。
3. Qasper：论文 QA，长上下文、证据定位强，适合你的 summary + snippet 机制。
4. NarrativeQA：长故事 QA，但生成式答案评估麻烦，成本更高。
5. BoolQ / CommonsenseQA 不推荐优先测：文本短或常识多，embedding 检索优势小，baseline 可能更强。