

面向 AAI 2027 的 Multi-Agent Debate 研究路线

一个先给出的判断

如果你的目标是在未来一轮里做出一篇更像主会论文、而不只是“把标准 debate 套到一个新任务上”的工作，我会把选题优先级排成：**谱感知的稀疏拓扑与加速共识 > 置信度校准与鲁棒共识 > 过程级证据驱动 debate > 为 debate 而训练的模型**。原因很明确：近两年的稳定进展主要来自**通信拓扑、决策协议、置信估计、预算控制**，而不是单纯增加 agent 数量或轮数；与此同时，新的理论与评测工作都在提示，如果 debate 没有改变信息结构或信念更新机制，它很容易退化成为“昂贵的多数投票”。[1]

换句话说，真正有发表潜力的 MAD 论文，不是“让 agent 多说一点”，而是“让谁对谁说、什么时候说、说什么、如何停、谁更可信”变成一个可学习或可证明的机制。Sparse topology、confidence-aware aggregation、adaptive stopping、context learning、tool augmentation，以及“打破错误多数”的理论机制，已经构成了 2025–2026 的前沿主线。[2]

就你当前积累而言，我最看好的是：**把分布式协作/共识理论真正引入多智能体辩论的通信设计与收敛分析**。这是因为你已经在附件工作里做出了稀疏通信、结构化聚合和端侧部署三件最难啃的事；下一步最自然、也最有“AAAI 味道”的升级，就是把这些经验抽象成**跨任务、跨模型、可分析的 debate control law**。

这个方向的研究全景

这条线的第一波工作，核心命题是：**单个 LLM 的自反思容易退化，多 agent 交互能否引入真正的“分歧—纠错”机制**。早期代表作强调，多智能体辩论可以缓解单模型反思中的“思维退化”，鼓励 divergent thinking；但与此同时，也有系统性研究指出，在强 prompting 充分的情况下，单 agent 往往已经接近最优，多 agent discussion 的额外收益并不总是稳定。换句话说，MAD 从一开始就不是“天然必胜”的，而是“条件性有效”的。[3]

第二波工作把注意力转向**通信结构与决策协议**。EMNLP 2024 的 sparse topology 论文表明，neighbor-connected 等稀疏拓扑可以在 reasoning 任务上保持甚至超过 fully-connected debate 的效果，同时把输入 token 成本压低 40% 以上；而且在 heterogeneous setup 里，把更强模型放到更高中心性的节点上会更有效。ACL 2025 的 CortexDebate 进一步把“稀疏 + 动态图 + 可信评价”做成了体系，报告在 GPQA 和 ARC-C 上分别有最高 9.00% 和 12.33% 的性能提升，并把上下文长度最多压缩 70.79%。与之并行，关于 voting 与 consensus 的工作说明：**决策协议本身就是性能来源之一**，而且在一些任务上，增加讨论轮数反而会伤害最终决策。[4]

第三波工作开始聚焦**置信度、异质性与评估方法**。ConfMAD 指出，agent 之间不仅要交换理由，还要交换**可校准的信心**，否则会出现错误答案被高置信 stubbornness 放大的问题；他们进一步发现，confidence calibration 还能提高正确共识的达成率。与此同时，评测与立场论文开始反思社区是否“高估了 MAD”：一方面，有研究指出 current MAD 的大部分收益其实可能来自 majority voting；另一方面，也有工作强调，若 agent 全来自同一模型族，所谓 debate 其实缺乏真正的 epistemic diversity。这个判断非常关键，它意味着下一代 MAD 论文要么做**真实异质性**，要么做**真实不对称性**，要么做**真实可验证性**。[5]

到 2026 年，前沿已经从“是否要 debate”转向“**如何把 debate 变得必要、可靠、便宜且可分析**”。iMAD 用 debate triggering 把 token 成本最高降到 92%；MARS 用 author-reviewer-meta-reviewer 架构在保持准确率的同时把 token 和时间大约减半；DALA 把通信当作稀缺资源，用 auction 来逼出 strategic silence；M2CL 开始学习每轮上下文；AceMAD 则直接提出“Martingale Curse”，认为标准 MAD 在期望上可能并不优于多数投票，除非引入打破对称性的机制；同一时期，Tool-MAD、DynaDebate、SDRL 分别把外部工具、初始化路径多样性和训练时 debate preparation 引入该领域。一个非常统一的结论正在形成：**有效的辩论必须创造额外信息，而不是重复已有信息**。[6]

你的两篇工作放在什么位置

你附件中的 **MedRing** 已经把“**稀疏通信拓扑 + 纠错转移分析 + 本地部署**”做成了一个非常清晰的范式：它把通信复杂度从 all-to-all 的 $O(N^2)$ 降到 ring 的 $O(N)$ ，而且不是只看最终 accuracy，还显式分析 wrong-to-right、right-to-wrong、still-wrong 等状态转移；在 MedQA 和 MedMCQA 上，它相对 best single agent、majority voting 和 one-shot dense debate 都拿到了更好的效果。**MAD-HAR** 则把 debate 推进到“**端侧受限、隐私敏感、异构小模型协作**”的情形，并加入了 structured rationale 与 authority-aware voting 机制，说明你不仅能做方法，还能把方法落到强约束应用里。

这两篇工作的组合非常有价值，因为它们恰好覆盖了当前 MAD 最重要的两条审稿关注点：第一，**效率与可部署性**，也就是 debate 不能只涨 token；第二，**可靠性与决策质量**，也就是不能只看最终答对率，还要看纠错是否真实发生、错误是否被传播或放大。事实上，最新的效率工作、评测工作和临床 benchmark 都在强调这两点：agentic system 不能默认比 single-agent 更好，尤其在高风险场景里，必须同时报告精度、成本、安全性与 hallucination 控制。[7]

因此，你下一篇论文最值得补上的，不是另一个应用壳，而是一个**更一般化、可复用、可分析的控制机制**。最自然的升级路径是：把 MedRing 的“结构化稀疏通信”从固定 ring 提升为可学习/可证明的自适应拓扑；或者把 MAD-HAR 里隐含的“agent authority”升级成**可校准、可鲁棒的信任分配与聚合规则**。这两条线都能自然继承你已有的实验习惯与系统能力。[8]

谱感知的稀疏拓扑与加速共识

问题定义

当前 sparse MAD 已经证明“少连边不一定差，甚至可能更好”；但现有方法大多要么是固定 ring / neighbor graph，要么是基于启发式 trust 的动态 pruning，仍然缺少一个更统一的问题表述：**在给定 token budget 和 agent 异质性的条件下，如何设计一个每题自适应、每轮可更新的通信图，使正确信息以更短路径传播，同时抑制错误共识的扩散？**这本质上就是把 MAD 重新表述为一个 budgeted distributed consensus / gossip 问题。Sparse topology、CortexDebate、GroupDebate、MARS、iMAD 都在不同侧面接近这个问题，但还没有把“图结构—收敛速度—纠错概率—token 成本”统一起来。[9]

更进一步地看，经典分布式共识和 gossip 文献告诉我们，**收敛快慢与图的代数连通性、混合速度、以及有向图上的影响力不平衡密切相关**；而 sparse MAD 的最新结果也说明，把更强模型放在高中心性节点上更有效。这给了一个非常漂亮的理论切口：你完全可以把“谁应该与谁交流”建模为一个**受度约束的谱优化问题**，让 debate graph 既保持低成本，又拥有足够大的 spectral gap 来加快正确信息扩散。[10]

方法描述

我建议把方法做成一个 **Spectral-Adaptive Debate Graph**。具体可分成四层。第一层是**初始信号抽取**：每个 agent 在 round 0 输出答案、置信分数、答案熵、简短 rationale 以及一个“可被攻击的薄弱点”摘要。第二层是**边权计算**：对任意两个 agent i, j ，定义一个边价值 v_{ij} ，综合考虑四项因素——可靠性（基于校准置信度和历史纠错率）、信息增益（答案分歧与 rationale 差异）、影响力（agent 能力或历史中心性）以及成本（传输 token 长度）。第三层是**谱约束图构造**：在总出度预算 B 下求解一个近似优化，目标是在控制总 token 的同时最大化图的有效连通性，并限制“单个超强 agent 支配所有节点”的风险。第四层是**稳定性停机**：借鉴 adaptive stability detection，在回答分布和图结构同时稳定后提前停止。这样的设计既继承了 ring/sparse 的效率优势，又比固定拓扑更能适应每道题的难度和异质性。[11]

如果你希望它更有理论味道，可以尝试证明两个结果。一个是**复杂度结果**：在平均出度受限时，总通信复杂度从 dense 的 $O(KN^2)$ 降到 $O(KNB)$ 。另一个是**收敛上界**：把 debate 的 belief update 近似成一个 time-varying directed mixing process，建立“达到 ϵ -agreement 的轮数”与每轮 mixing matrix 的谱性质之间的关系；再进一步分析强 agent 放在高中心性位置是否能降低 wrong-to-right 的平均 hitting time。这个理论口径和你想做的“把分布式协作理论应用到 MAD”是高度对齐的。[12]

实验方案

数据集与任务设置上，我建议用一个“医疗 + 通用 reasoning”的双轴评测。医疗轴使用 MedQA 与 MedMCQA，直接延续你的 MedRing 路线；通用轴使用 MMLU-

Pro、GPQA、BBH 或 MATH/GSM8K，以避免被审稿人认为方法只对某一窄领域有效。Sparse topology、CortexDebate、iMAD 和 Voting-or-Consensus 一类论文已经在这些基准上建立了比较成熟的先例。[13]

主实验应该围绕“效果—成本—收敛”三条主线展开。效果上，对比 best single agent、majority voting、all-to-all MAD、固定 ring、neighbor-connected sparse MAD、CortexDebate、GroupDebate、MARS、iMAD，以及你的自适应谱图方法；成本上，报告平均 token、平均 wall-clock latency、平均轮数、单位正确样本成本；收敛上，报告 consensus rate、time-to-consensus、wrong-to-right / right-to-wrong 迁移率，以及每轮图的平均度与谱指标。这里最能打动审稿人的，不只是“更准”，而是用更少通信换来更快达成正确共识。[9]

消融实验需要相当系统。至少要做：固定图 vs 动态图；有没有谱正则；只用答案差异 vs 加入 rationale 差异；强 agent 是否放到高中心性位置；不同出度预算 B ；有无早停；异构模型数目从 3 到 7 的扩展；把 dynamic graph 换成随机 gossip 边采样的版本。若干重要反例也要展示，比如题目很简单、single-agent 已经正确时，自适应图是否自动保持“少说话”。这能直接回应 iMAD、MARS 与 DALA 所强调的 resource rationality。[14]

依赖硬件方面，这个方向最友好，因为它基本是 inference-time 方法。若使用 7B–14B 开源模型做完整 sweep，比较舒服的配置是 4×A100 80GB 或 8×L40S；如果你延续本地实验风格，也可以像 MedRing 那样做顺序装载与 offloading，用 2×4090 或更小配置先完成 MedQA/MedMCQA 的证明性实验，再把大规模横向基准放到服务器上跑。这样的分阶段路线既现实，也符合你已有系统经验。

置信度校准与鲁棒共识

问题定义

MAD 的第二个核心瓶颈不是“连边太多”，而是“**错误 agent 过于自信，正确少数派无法上浮**”。ConfMAD 已经清楚地表明，confidence expression 和 calibration 会影响 debate dynamics；Voting-or-Consensus 与 Debate-or-Vote 两篇工作则进一步提示，很多情况下，decision rule 的影响不亚于 communication protocol。再加上 2026 的 AceMAD 把“错误多数把 debate 拉向错误共识”的现象正式理论化为 Martingale Curse，这使得一个更强的问题浮现出来：**能否把 LLM debate 做成一种带鲁棒保证的加权共识，而不是无约束的相互说服？** [15]

这条线尤其适合你做，因为它和分布式系统中的 **Byzantine-resilient consensus / robust aggregation** 有天然对应关系。分布式学习里已经发展出 coordinate-wise median、trimmed mean、geometric median、Krum 等鲁棒聚合思想，目的就是让少量坏节点或异常更新不能拖垮全局。把这个思想迁移到 MAD，很容易形成一个既新颖又合理的命题：**在存在弱 agent、坏 agent、sycophantic agent 或误导性工具证据时，怎样设计校准与聚合机制，保证 debate 至少不比投票更差，并尽量从错误多数中恢复正确答案。** [16]

方法描述

我建议把方法做成一个 **Confidence-Calibrated Byzantine-Robust Debate**。第一步，每个 agent 不只输出答案和 rationale，还输出两种置信度：一种是基于答案 token 概率的 **LN confidence**，另一种是 self-verbalized confidence；之后在独立 validation split 上做 Platt scaling 或 temperature scaling，使不同模型的 confidence 进入同一个可比较尺度。ConfMAD 的结果已经暗示 Platt scaling 往往更稳定，这可以直接作为你的起点。[17]

第二步，引入**双重信任分数**。其一是**自信任**，也就是校准后的自置信度；其二是**互信任**，也就是 agent 对其他 agent 观点的预测能力。这里可以借鉴 AceMAD 的 peer prediction 思想：真正知道答案的 agent，不仅更可能答对，也更可能预测别人会如何犯错；而幻觉多数派通常对“别人为什么会错”并不敏感。你可以把这种“认知势能差”转成一个信用分，然后在通信图和最终聚合时同时使用。这样做的关键不是把强者声音放大，而是让**能解释他人错误的人**获得更高权重。[18]

第三步，做**鲁棒聚合与鲁棒停机**。最终决策不再是朴素 majority vote，而是可以针对离散答案做 trimmed voting、对连续 confidence mass 做 weighted geometric median，或者对 claim-level scores 做 centerpoint/median-style aggregation。停机条件也不再是“大家答案相同”，而是“高信用质量的分布已经稳定”。如果你愿意再往理论前进一步，可以尝试给出一个针对 f -corrupted agents 的恢复界，比如：当坏 agent 比例低于某阈值、且校准误差受控时，最终错误共识概率上界如何随 agent 数、初始正确率和聚合规则变化。这种理论味道会很强。[19]

实验方案

数据集上，我建议采用三种压力测试场景。第一类是高难 reasoning：MMLU-Pro、GPQA、BBH、MATH；第二类是医疗问答：MedQA、MedMCQA；第三类是高风险 factual / error detection 场景，例如 BioNLP 2025 的 medical note error detection 任务。这样你既能展示通用性，又能用医疗场景强调鲁棒性与安全性。[20]

主实验不要只做 clean setting，而要显式构造 corrupted setting。你可以设置几种 agent 污染方式：一是弱模型替换，二是错误置信膨胀，三是 prompt-sycophancy，四是 retrieval 污染，五是随机答案但高自信的“坏 agent”。clean setting 下，对比 majority voting、标准 MAD、ConfMAD、Voting-based protocols、AceMAD 风格 peer-prediction 聚合，以及你的鲁棒方法；corrupted setting 下，看各方法的性能下降曲线。真正有说服力的结果不是绝对准确率，而是**随着坏 agent 比例提高，谁最慢崩**。[21]

核心指标建议至少包括：accuracy、wrong-majority recovery rate、rectification / degradation、ECE、Brier score、consensus rate、clean-to-corrupted performance drop，以及“一个高置信错误 agent 能拖坏多少样本”的 influence metric。这里 MedRing 的纠错转移分析和 ConfMAD 的 calibration analysis 可以直接拼起来，形成一个很强的 evaluation package。 [22]

消融实验则要回答五个问题：是否真的需要 calibration；LN vs SV 哪个更稳；peer-prediction 是否单独有效；鲁棒聚合是关键，还是信任估计更关键；不同 corruption rate 下哪个模块先失效。你还可以做一个非常精彩的 ablation：把正确少数派的人数固定得很小，观察方法是否还能“翻盘”。如果翻盘能力强，这条线就会和 AceMAD 的理论问题形成直接呼应。[23]

依赖硬件方面，这个方向也不算重。主计算仍在 inference-time，多数成本来自多 agent 采样；confidence calibration 本身只需要在一个 validation split 上训练小型校准器，CPU 或单卡即可。若做大规模 corruption sweep，用 4×A100 80GB 或 8×L40S 最稳；若只做医疗和 reasoning 两三组主基准，2×4090 也足以先跑出一版可投稿结果。

过程级证据驱动辩论

问题定义

如果你更想做一条“**机制创新 + 强应用场景**”的路线，我最推荐的是把 debate 从“答案级争论”升级到“**过程级证据协商**”。当前很多 medical MAD 或 fact-based MAD 的一个共同问题是：agent 讨论的是结论或者整段 rationale，而不是逐条 claim 的证据支持关系。MRCD 已经指出，医疗多 agent 的一个关键瓶颈是**信息同质化**：大家访问相似知识，最后形成的是 artificial consensus，而不是真正的 multidisciplinary consultation。Tool-MAD 则表明，只要把外部工具和 adaptive retrieval 引入 debate，事实核查类任务还能继续涨。[24]

这条线特别适合你，是因为 **MedRing** 已经在医疗 QA 里证明了稀疏纠错有效，而临床 benchmark 又提醒我们：agentic system 在真实医疗场景里仍然会出现显著 hallucination，不能靠“多问几轮”自动修复。因此，一个更有前景的问题是：**能否把 debate 的单位从整体答案变成可检查的 medical claims，并且只在存在证据冲突的地方触发检索和进一步辩论？**这样一来，token 花在“争议点”上，而不是花在重复整个 reasoning trace 上。 [25]

方法描述

方法上，我建议你设计一个 **Claim-Graph Evidence Debate**。给定一道医疗题或临床文本，先让每个 agent 生成一个简短答案和一个 **claim graph**：节点是诊断、症状解释、药物相互作用、禁忌证、证据来源等，边表示 supports / contradicts / requires。然后，系统只抽取那些**跨 agent 冲突最大的 claim 子图**进入 debate。与其让 agent 读完整段对方理由，不如只读“发生冲突的 claim + 支持证据 + 反驳请求”。这会自然降低上下文长度，并使 debate 更接近真正的临床会诊。[26]

接着，在争议 claim 上触发**专家招募与定向检索**。你可以借鉴 MRCD 的 dynamic expert recruitment：例如同一问题中只在必要时拉入 cardiology、pharmacology、radiology 等角色，每个角色拥有不同的 domain-specific retriever 或 guideline source；再借鉴 Tool-MAD 的 adaptive retrieval，让 query 随 debate 演化，而不是只

在开头检索一次。最终 judge 不再只看哪个答案票数最高，而是优化一个组合目标：claim support coverage、claim contradiction resolution、answer relevance 与 final consistency。这个设计既有方法新意，也非常容易讲清楚“为什么比标准 RAG 或标准 MAD 更合理”。[24]

实验方案

数据集方面，我建议把实验分成两个任务型。第一个是 **medical QA**: MedQA、MedMCQA；第二个是 **medical error detection / factual auditing**: BioNLP 2025 的 medical note error detection。这样的组合非常稳，因为前者检验复杂推理，后者检验 claim 级 factuality。若你想增强“专科协作”的展示效果，还可以在 MedQA/MedMCQA 上手工或自动构建 specialty split，把问题按 cardiology / neurology / pharmacology 等主题分层统计。[27]

主实验至少要和五类基线比较：single-agent CoT / RAG；majority voting；MedRing 一类的 sparse debate；MRCD 一类的 specialist + RAG debate；Tool-MAD 一类的 tool-augmented debate。报告不仅包括最终 accuracy，还要包括 claim-level faithfulness、unsupported-claim rate、evidence precision/recall、检索调用次数和总 token。这里最好的叙事应该是：你的方法不是“讨论更多”，而是“把讨论聚焦到最有争议、最需要证据的那几步”。[24]

消融实验建议围绕四个组件展开：claim graph 是否必要；只在 disagreement 时检索是否优于固定每轮检索；专家招募是否优于固定角色；最终 judge 是否必须看 claim evidence score。再加一个非常关键的 ablation：把 evidence source 统一成同一个医学知识库，看看效果是否下降。若下降明显，就可以很有力地证明“信息异质性”而不是“agent 个数”才是关键。[28]

依赖硬件方面，若只做文本医疗任务，4×A100 80GB 足以完成高质量实验；如果你的 retrieval 模块以轻量 BM25 + embedding reranker 为主，2×A100 也能先出结果。更重要的是，这条线很适合做**本地可部署版本**：你在 MedRing 和 MAD-HAR 里已经证明过本地异构小模型协作是可行的，所以完全可以把“隐私友好、医院内网可部署”当作方法价值的一部分，而不是附带卖点。

为 debate 而训练的模型

问题定义

当前大多数 MAD 系统仍然是“把为单人推理训练的模型，硬塞进多人辩论框架里”。这会带来一个根本问题：模型会解题，不代表它会听别人、评估别人、修改自己。2026 年的 SDRL 已经明确提出，test-time debate 要想持续有效，训练时就应让模型接触 debate-conditioned reasoning；DynaDebate 也说明，如果初始路径不多样，后续 debate 容易退化成多数投票。于是，一个很有前景的问题就是：能否把 debate 能力本身训练出来，而不是完全依赖推理时的 prompt engineering？[29]

这条方向比前两条更重，但它有一个非常明显的理论和经验双重价值：如果 Debate-or-Vote 的结论成立，即标准 debate 往往不能在期望上超越 voting，那么一条可行出路就是**训练 agent 学会更好的 private critique 与 belief revision**，从而让“多 agent”真正产生额外信息，而不是彼此重复。SDRL 的核心 insight 正是这个：同时优化独立解题能力与 debate-conditioned revision 能力。[30]

方法描述

我建议把方法做成 **Debate-Ready Reasoning Model**。做法可以分三步。第一步，用一个强 teacher committee 生成 debate traces，包括初始解、对他人回答的 critique、修正后的二轮回答、以及最终定稿。第二步，对一个 7B–8B 开源 reasoning model 做 LoRA/QLoRA 微调，联合优化三类目标：独立求解损失、debate-conditioned revision 损失、以及 critique quality 损失。第三步，再加一个轻量的 budget-aware 目标，让模型学会在“无需 debate”时保持节制，在“值得 debate”时给出高信息密度 critique，这样就能自然接上 iMAD 一类 debate trigger。[31]

如果你想让这条线更有新意，可以再加入一个 **policy distillation** 视角：把多 agent committee 的行为蒸馏成一个单模型里的两个 head——一个是 solver head，一个是 critic/reviser head；最终推理时，既可以单独运行它获得更强 single-agent，也可以把多个同构或异构的 debate-ready model 放到 MAD 里继续协作。这样，你不仅可能提高 MAD 本身，还可能得到一个“比原模型更会自我修正”的 student，这种双赢结果通常很受欢迎。[32]

实验方案

数据集上，我建议采用“training on generic reasoning, testing on domain transfer”的策略。训练阶段可用 MATH、GSM8K、MMLU 这类有可验证答案的任务构造 debate traces；测试阶段同时评估 MMLU-Pro、GPQA、MedQA、MedMCQA，看看训练得到的 debate skill 是否能迁移到医疗 reasoning。这样设计能避免审稿人质疑你只是记住了训练集形式。[33]

主实验需要同时报告 single-agent 和 multi-agent 两种收益：一方面，看训练后的模型单独推理是否更强；另一方面，看把它放到同样的 debate protocol 中，是否比未训练的同规模模型更会纠错、更会吸收他人信息。对比对象至少包括原始 base model、自一致性、未训练 MAD、iMAD，以及 SDRL。若你能证明“同样的拓扑与同样的 agent 数，只因为模型更会辩论，最终性能就更高”，这篇论文的识别度会很强。[34]

消融实验建议回答三件事：只训练单人解题是否足够；只训练 critique 不训练 revision 是否足够；budget-aware loss 是否真能减少无效发言。再加一个跨 protocol 泛化实验：训练时只见过 ring debate，测试时换成 sparse graph 或 reviewer-based protocol，看看 debate-ready skill 是否保持。若能保持，说明你学到的是“如何处理别人的推理”，而不是某种固定 prompt 模板。[35]

依赖硬件方面，这条线是四个方向里最重的。若在 7B–8B 模型上做高质量 LoRA/QLoRA 和多轮 trace 训练，比较舒适的配置是 8×A100 80GB 或 4×H100 80GB；预算紧张的话，可以先在 4×A6000 或 4×4090 上做小规模版本，只训练 critique/revision adapter，把论文重点放在“debate skill 是否可迁移、是否能减少无效 debate”。这条线更适合作为你第二篇或更长期的主线，但一旦做顺了，上限也最高。[36]

[1] [2] [4] [8] [9] [14] [33] aclanthology.org

<https://aclanthology.org/2024.findings-emnlp.427.pdf>

[3] aclanthology.org

<https://aclanthology.org/2024.emnlp-main.992.pdf>

[5] [15] [16] [17] [21] [22] [23] Enhancing Multi-Agent Debate System Performance via Confidence Expression

<https://arxiv.org/pdf/2509.14034>

[6] [7] [34] iMAD: Intelligent Multi-Agent Debate for Efficient and Accurate LLM Inference

<https://ojs.aaai.org/index.php/AAAI/article/view/40181/44142>

[10] [reza-tac07.pdf](#)

<https://labs.engineering.asu.edu/acs/wp-content/uploads/sites/33/2016/09/Consensus-and-Cooperation-in-Networked-Multi-Agent-Systems-2007.pdf>

[11] [19] Multi-Agent Debate for LLM Judges with Adaptive Stability Detection

https://arxiv.org/abs/2510.12697?utm_source=chatgpt.com

[12] web.stanford.edu

<https://web.stanford.edu/~boyd/papers/pdf/gossip.pdf>

[13] [20] aclanthology.org

<https://aclanthology.org/2025.findings-acl.495.pdf>

[18] Breaking the Martingale Curse: Multi-Agent Debate via Asymmetric Cognitive Potential Energy

https://arxiv.org/abs/2603.06801?utm_source=chatgpt.com

[24] [26] [28] Proceedings of the 1st Workshop of LLM Reasoning on Medicine: Challenges, Opportunities, and Future

<https://aclanthology.org/2025.llm4medr-1.pdf>

[25] Benchmarking large language model-based agent systems for clinical decision tasks | npj Digital Medicine

<https://www.nature.com/articles/s41746-026-02443-6>

[27] Error Detection in Medical Note through Multi Agent Debate - ACL Anthology

<https://aclanthology.org/2025.bionlp-1.12/>

[29] [31] [32] [35] [36] Prepare Reasoning Language Models for Multi-Agent Debate with Self-Debate Reinforcement Learning

https://arxiv.org/abs/2601.22297?utm_source=chatgpt.com

[30] Debate or Vote: Which Yields Better Decisions in Multi-Agent Large Language Models? | OpenReview

<https://openreview.net/forum?id=iUjGNJzrF1>